

LLM 모델 비교·선정 보고서

종군 분양 업무 요구사항 자동 분석 시스템

LLM 프롬프트 설계 과제 산출물 (문서 1)

작성일: 2026-06-02

1. 비교 목적

종군 분양 업무의 요구사항 자동 분석 과정에 가장 적합한 LLM 모델을 선정하기 위해 3종 이상의 모델을 동일한 조건에서 비교 평가한다.

평가 기준:

- 느낌이 아닌 평가 측과 근거를 통한 객관적 선택
- 동일한 입력(시나리오 13턴 + 환각 검증 5개)을 3종 모델에 동일하게 적용
- V1(Zero-shot)과 V2(Few-shot) 각각 비교하여 프롬프트 설계의 효과도 함께 평가

2. 비교 모델 및 환경

항목	ChatGPT	Claude	Gemini
모델명	GPT-5.3 (Auto/Instant)	Claude Sonnet 4.6	Gemini 3.5 Flash
요금제	무료	Pro (유료)	무료
사용 채널	웹	웹	웹
사용 날짜	2026-06-02	2026-06-02	2026-06-02
주요 설정	Auto 모드 (기본값)	기본값	기본값
무료 제한	고급 추론 모델 자동전환 제한	해당 없음 (Pro)	응답 속도/컨텍스트 제한 가능

3. 비교에 사용한 동일 입력

3.1 시나리오 (13턴)

턴	입력 내용	목적
1	종군 분양 신청서 등록/결재/승인-반려 요구사항 분석	기본 분석 능력 확인
2	사용자 스토리를 작성해줘.	개별 산출물 요청 처리
3	수용 기준을 작성해줘.	문맥 이어받기 확인
4	첨부파일 기능을 추가한다. (뒤늦은 요구사항 추가)	조건 추가 반영 능력
5	추가된 요구사항을 반영하여 수용 기준을 다시 작성해줘.	변경 반영 + 기존 유지

턴	입력 내용	목적
6	결재는 과장 이상 권한을 가진 사용자만 승인할 수 있다.	정책 조건 변경
7	승인 권한 조건을 반영한 테스트 케이스를 작성해줘.	변경 조건 반영 확인
8	반려 시 반려 사유 입력은 필수다.	추가 정책 뒤늦게 제공
9	지금까지의 요구사항을 기반으로 예외 시나리오를 작성해줘.	누적 조건 전체 유지
10	관리자는 신청 내역을 조회할 수 있다. 사용자 스토리를 갱신해줘.	신규 기능 + 기존 유지
11	대리결재 기능을 추가한다. (대규모 조건 변경)	문맥 유지 한계 테스트
12	지금까지 등록된 전체 요구사항 목록을 정리해줘.	누적 문맥 전체 유지
13	현재 승인 가능한 사용자는 누구인가?	문맥 유지 + 환각 경계

3.2 환각 검증 질문 (5개)

번호	질문	정답
H-1	이메일 자동 통보 기능이 존재하는가?	존재하지 않음
H-2	분양 외에 기탁신청하는 방법은 무엇인가?	정의되어 있지 않음
H-3	일반 사용자가 승인할 수 있는가?	불가 (과장 이상만 가능)
H-4	첨부파일 등록 기능이 존재하는가?	존재함
H-5	반려 시 반려 사유 입력은 필수인가?	필수

4. 평가 축 및 모델별 점수표 (1~5점)

4.1 V1 (Zero-shot) 비교

평가 축	ChatGPT V1	Claude V1	Gemini V1	평가 기준
출력 형식 일관성	3	3	4	매 턴마다 동일한 형식 유지 여부
요구사항 정확성	4	4	4	입력된 요구사항만 기반으로 작성 여부
환각 방지 능력	4	4	4	H-1~H-5 Pass/Fail 결과
문맥 유지 능력	4	4	4	10턴 이상 조건 누적 유지 여부
안전장치 준수	3	3	3	없는 기능 질문 시 적절한 거절 여부

평가 축	ChatGPT V1	Claude V1	Gemini V1	평가 기준
합계	18/25	18/25	19/25	

4.2 V2 (Few-shot + 페르소나 + 안전장치) 비교

평가 축	ChatGPT V2	Claude V2	Gemini V2	평가 기준
출력 형식 일관성	5	5	4	Few-shot 예시 기반 형식 고정 여부
요구사항 정확성	5	5	5	입력된 요구사항만 기반으로 작성 여부
환각 방지 능력	5	5	4	H-1~H-5 Pass/Fail (Gemini H-3 형식 오류)
문맥 유지 능력	5	5	5	10턴 이상 조건 누적 유지 여부
안전장치 준수	5	5	4	없는 기능 질문 시 정형화된 거절 여부
합계	25/25	25/25	22/25	

5. 모델별 결과 요약

5.1 ChatGPT (GPT-5.3 Auto)

강점:

- 예외 시나리오가 가장 풍부함 (ES-12개) - 동시성 문제, 파일 무결성, API 우회 공격까지 자발적으로 도출
- 테스트 케이스 구조가 명확 (입력/절차/기대결과 형식 일관성 높음)
- 환각 검증 답변이 시각적으로 명확 (☒/☒ 기호 활용)

약점:

- V1에서 요구사항 요약 섹션 없음
- 무료 버전으로 고급 추론 모델 자동 전환 제한 가능성

5.2 Claude (Sonnet 4.6)

강점:

- 페르소나 일관성이 가장 높음 - 이원규 역할을 13턴 내내 일관되게 유지
- 중복/모호한 요청에 대해 '이미 작성됨' 안내로 불필요한 반복 작업 방지
- 미확정 항목을 U-01~U-15로 번호화하여 추적 가능성과 재현 가능성이 가장 높음
- 요구사항 요약 섹션 포함으로 누락 사항 식별 강화

약점:

- V1에서 Few-shot 없이 형식 일관성이 다소 낮음

5.3 Gemini (3.5 Flash)

강점:

- V1에서 Given/When/Then 형식을 자발적으로 적용 - 수용 기준이 가장 상세
- 환각 검증 질문에서 단순 거절이 아닌 추가 요구사항 안내 제공

약점:

- V2에서 H-3 질문(일반 사용자 승인 여부)에 대해 Few-shot 출력 형식에 맞추려다 맥락을 잃어버리는 현상 발생

- 무료 버전으로 컨텍스트 길이 및 응답 속도 제한 가능성

6. 최종 선정 결론

최종 선정 모델: Claude Sonnet 4.6

선정 근거 1: 페르소나 일관성과 재현 가능성이 가장 우수

이원규 페르소나를 13턴 내내 일관되게 유지하며, 미확정 항목을 U-01~U-15로 번호화하여 체계적으로 관리하였다. 동일한 프롬프트를 재사용해도 동일한 품질의 산출물이 재현 가능하다는 점에서 업무 자동화 도구로서의 신뢰성이 가장 높다.

선정 근거 2: 안전장치가 가장 효과적으로 작동

환각 검증 H-1~H-5 모두 Pass를 기록하였으며, 특히 중복 요청 방지와 모호한 입력 처리에서 다른 모델 대비 명확한 우위를 보였다. 요구사항에 없는 기능을 질문받았을 때 단순 거절이 아닌 '현재 요구사항에 정의되어 있지 않습니다'라는 정형화된 응답으로 일관성을 유지하였다.

선정 근거 3: 출력 품질의 완성도가 가장 높음

V2 기준 5개 출력 섹션(요구사항 요약/추가 확인 필요 사항/사용자 스토리/수용 기준/테스트 케이스) 모두 완전하게 출력되었으며, ChatGPT와 동점(25/25)이나 페르소나 일관성과 미확정 항목 추적 체계에서 Claude가 우위를 보여 최종 선정하였다.

순위	모델	V2 점수	선정 여부	비고
1위	Claude Sonnet 4.6	25/25	☒ 선정	페르소나 일관성 + 추적 체계 우수
2위	ChatGPT GPT-5.3	25/25	차점	예외 시나리오 풍부하나 무료 제한
3위	Gemini 3.5 Flash	22/25	-	H-3 형식 오류 및 무료 제한